ForgeMind V4

全流程训练与部署教程

MiniMind 工程基础 · QLoRA · 数据治理 · Agent 评测 · 本地 API



按本机 D 盘实际训练记录编写 · 含数据审计、命令模板和验收门禁

状态提示：本次 V4 试训在 80 / 512 步暂停，尚无可用 checkpoint。

工程快照：2026-10-12 · 所有路径均指向 D:\ForgeMind-Work\project

01 先弄清楚：V4 到底是什么

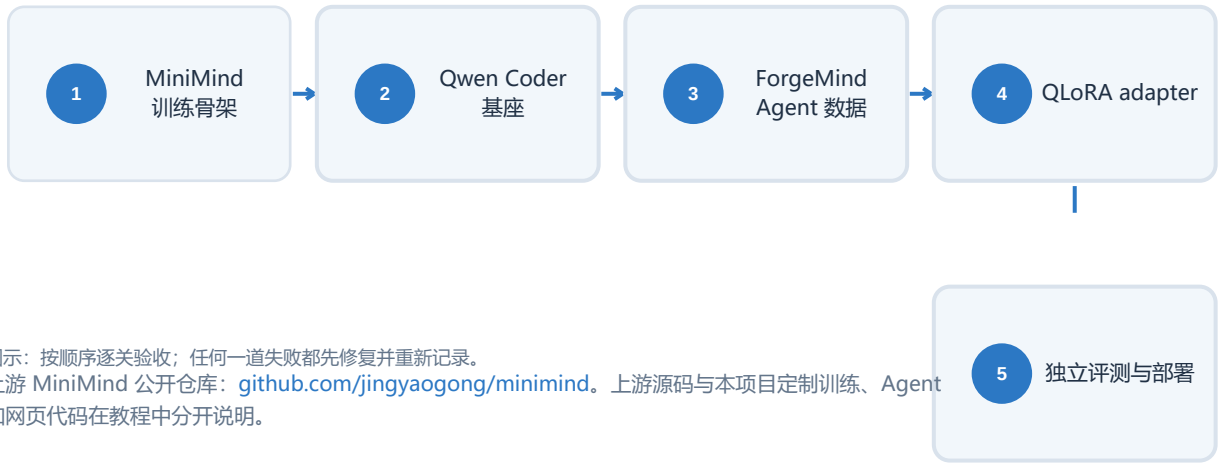
这份教程里的“V4”指 ForgeMind 代码 Agent 的一轮经过许可范围整理、真实 fixture 结果验证和 tokenizer 预检的 SFT 候选训练流程。它是在 Qwen2.5-Coder-7B-Instruct 上做 NF4 QLoRA 微调，不是从零训练一个 7B 基础模型，也不是 MiniMind 上游正式发布的版本号。

名称	本机记录中的含义
MiniMind	上游开源的轻量大模型训练与教学工程；用于理解 tokenizer、Transformer、预训练、SFT、LoRA 与模型导出流程。
ForgeMind	在上游工程基础上整合本地代码 Agent、网页、专家知识库、搜索和兼容 API 的项目。
V4 数据候选	2026-10-11 生成的 4,600 行混合集，含经过本地 fixture 验证的工具轨迹；SHA-256 固定。
V4 训练试跑	2026-10-12 启动，计划 512 步；采样日志在 80 步处结束，当前无 checkpoint。
网页当前模型	本地网页当前仍使用 Qwen2.5-Coder-7B-Instruct Q4 GGUF 基座；并未加载这次 V4 adapter。

阅读这份教程时的关键区分
“数据准备完成”“训练跑到某一步”“adapter 通过验证”“网页实际切到新模型”是四种不同状态。只有最后两项都留下证据，才能说 V4 已进入可用版本。

上游项目和工程关系

基座提供通用代码能力；微调只调整低秩 adapter。



图示：按顺序逐关验收；任何一道失败都先修复并重新记录。
上游 MiniMind 公开仓库：github.com/jingyaogong/minimind。上游源码与本项目定制训练、Agent 和网页代码在教程中分开说明。

02 全流程总览

训练大模型不是“喂数据后看 loss”。V4 必须先保证数据许可与来源可追踪，再用独立 holdout 检查相似内容，随后才启动小规模试训；训练后要与未微调基座配对评测，再决定是否导出并切换服务。

V4 决策链：每一步都应留下日志、哈希或评测文件。



图示：按顺序逐关验收；任何一道失败都先修复并重新记录。

阶段	产物	进入下一步的条件
环境	基座权重、Python/torch/bitsandbytes、固定命令	GPU 空闲、磁盘与路径达标；没有触碰其他应用。
数据	JSONL、来源清单、许可说明、SHA-256	无重复拼接；训练/验证按任务组分开；holdout 不参与训练。
训练	逐步日志、验证 loss、adapter checkpoint	数值稳定、按设定频率保存；中断后确认恢复点。
评测	基座与 adapter 成对的任务级和案例级分数	新 adapter 不回退；重复运行结果稳定。
部署	合并/转换权重、GGUF、模型 API 和网页版本号	部署模型指纹匹配已评测 checkpoint，API 和真实任务均通过。

03 工程结构与职责

工作区位于 D 盘。`source/` 是 MiniMind 工程副本及 ForgeMind 运行时源码；顶层 `dataset/`、`eval/`、`runs/` 和 `logs/` 存放训练数据、审核、结果与日志。数据或模型文件可能通过目录链接位于 `shared/`，应以本机 `Get-Item` 的 LinkType/Target 和脚本实际路径为准。

路径	内容与用途	不要混淆
source/model、source/trainer	模型结构、tokenizer/训练工具、LoRA 与训练脚本	上游 MiniMind 训练框架不等于 ForgeMind Web 服务。
source/agent_runtime、source/web、source/scripts	文件读取/编辑工具、网页/API、桥接与启动逻辑	代码编辑与代码执行是不同权限；执行默认关闭。
dataset/、source/dataset/	许可范围候选集、数据构建脚本与 manifest	改动数据后必须重算 hash 并重新审计。
eval/、eval/results/	预检、holdout 审核、任务套件和评分报告	训练集 validation loss 不能替代独立代码任务。
runs/、output/weights/	adapter、checkpoint、量化/部署模型	目前 V4 pilot 没有可用 checkpoint。
logs/、tmp/、cache/	运行日志与缓存	临时目录、模型缓存都应固定到 D 盘。
output/pdf/	教程 PDF 等交付文件	本手册生成于此目录。

路径检查命令

PowerShell：

```
Get-Item .\source, .\dataset | Select FullName,LinkType,Target
```

确认训练脚本、临时目录、模型 cache 和输出都落在 D 盘后再启动。

04 训练前：先检查资源，不要硬顶

本次 V4 launch 记录显示 GPU 为 RTX 5070 Laptop，训练启动时可用显存约 6,893 MiB；模型基座位于本机 D 盘 shared 模型目录。训练期间显存被大量占用，所以要把 ForgeMind
推理服务停在门控之外，但不关闭未知桌面程序。

检查项	本项目建议/已知条件	操作
磁盘	模型分片、环境、输出和 cache 总量较大；建议留出 30 GB 以上空间	检查 D 盘剩余空间；TEMP、TMP、HF_HOME、TORCHINDUCTOR_CACHE_DIR 全设到 D。
GPU 显存	V4 启动时可用约 6.7 GiB；起跑前需连续达到门槛	用 nvidia-smi 查看总量、占用与温度，不杀其他进程。
系统内存	大模型加载与数据预检会占用系统内存	先关闭自己确认属于 ForgeMind 的服务；不要中止用户其他工作。
软件	Python 3.12 venv、CUDA/PyTorch、transformers、PEFT、bitsandbytes	记录 python -V、torch/CUDA 版本和训练脚本 commit/hash。
基座	Qwen2.5-Coder-7B-Instruct safetensors 固定目录	记录模型来源、版本、配置、tokenizer hash；训练后不可换基座。

COMMAND / CONFIG

```
Set-Location D:\ForgeMind-Work\project
$env:TEMP='D:\ForgeMind-Work\shared\tmp\training-temp'
$env:TMP=$env:TEMP
$env:HF_HOME='D:\ForgeMind-Work\shared\tmp\hf-home-forgemind'
$env:TORCHINDUCTOR_CACHE_DIR='D:\ForgeMind-Work\shared\tmp\training-temp\torchinductor_cache'
.\.venv\Scripts\python.exe -c "import torch; print(torch.__version__, torch.cuda.is_available())"
```

训练前 GPU 门禁
先确认可用显存连续达到训练计划门槛、服务端口和 GPU 分配状态已记录。若显存不足，延迟训练；不要强制结束其他应用或用 CPU 盲目启动 7B 长训练。

05 数据工程：许可、来源、去重和可验证回执

V4 训练集由来源清楚的编程数据与项目自有工具轨迹混合而成。原始工具样本先生成隔离 fixture，再实际运行 fixture tests；只有观察到真实工具返回与退出码后，样本才标记为验证通过。许可清单随数据记录保留。

不把“模型说测试通过”当成测试记录。



图示：按顺序逐关验收；任何一道失败都先修复并重新记录。

组成	行数	说明
Magicoder Python 代码样本	3,000	数据集卡标注 MIT；分发时保留所需 attribution/notice。
项目自建已验证 Agent 轨迹	1,000	CC0 项目数据；100 个完整 fixture episode，每个 episode 实际测试通过。
Magicoder-derived patch 格式样本	600	MIT 来源，需遵守源数据集的归属与 notice 要求。
当前混合集	4,600	SHA-256: 30a24225826a7229d466224e3918a1d1af73131cedd8eecc822733b9651a4a47。

许可边界
上游 MiniMind 为 Apache-2.0；混合集含 MIT 数据。公开源码可附上游 license 和 attribution；权重或训练数据再分发前，要重新核查各数据集 license、条款和归属文件。不要把“可以本地研究”直接等同于“可以公开分发衍生权重”。

06 数据预检：长度、任务分组与 holdout

预检调用与训练相同的 Qwen tokenizer 和数据 fit/split 函数，避免先训练才发现对话截断或 holdout 泄漏。当前结果是审计快照，不是永久保证；每次更改数据、tokenizer 或切分 seed 都需要重新执行。

门禁	V4 实际结果	解释
数据 hash / 行数	4,600 行；hash 与 manifest 一致	先确认输入文件没有被后续任务覆盖。
1024 token 拟合	4,578 可训练；22 行超长丢弃；无 compact	丢弃原因可追溯；不要静默缩短 target。
任务分组 90/10	4,121 train / 457 validation；2,806 / 297 task groups	train 与 validation 的精确任务组交集为 0。
fixture 证据	100 份证据；100/100 测试通过；未验证成功回执 0	只证明这些合成单文件 fixture，不证明任意生成代码安全。
holdout lexical audit	对 8 个函数任务与 repo-agent 套件检查 exact/string/token overlap	没有精确命中；token overlap 不是语义独立性证明。
active holdout	未用于本次训练	保留为训练后盲测；不要在调提示时查看答案。

COMMAND / CONFIG

```
# ■■■■■■■■■■■■■■■■■■■■/■■■■ D ■
.\.venv\Scripts\python.exe eval\preflight_forgemind_v4_training_data.py
.\.venv\Scripts\python.exe eval\audit_forgemind_v4_holdout_overlap.py
# ■■■■ JSON ■■ dataset_sha256■manifest_sha256■■■■ holdout ■■
```

严禁重复拼接

V3 manifest 已包含早期 v4 的 1,000 行工具样本。不要把 v3 4,600 行再与 v4 1,000 行相加，否则会重复训练。当前 2026-10-11 V4 混合集有自己的 SHA 和来源清单。

07 V4 训练：配置、启动与当前进度

这次小规模训练用于判断数据和配方能否稳定跑通，不能用单一训练 loss 判断 coding 能力。启动记录将 eval/preview 周期设为 128，计划跑 512 个 trainer step。

项目	本次记录
启动时间	2026-10-12 17:47（Asia/Shanghai）
基座/量化	Qwen2.5-Coder-7B-Instruct；NF4 量化训练
微调方式	QLoRA rank 8；作用模块 q_proj、v_proj
学习率/序列	2e-5；最大长度 1,024 token
计划/采样	512 steps；预览 checkpoint 128；验证间隔 128
起跑资源	RTX 5070 Laptop GPU；启动时空闲 6,893 MiB
数据	4,600 行固定候选，SHA-256 如上一页
种子/epoch	启动 manifest 未记录；不要自行假定或补写为已知值。



日志最后记录 step=80；训练进程已退出。该图只表示已记录步数，不代表质量或完成率。

当前结论
启动日志最后写到 80/512 步，随后用户要求暂停；训练进程已退出，run manifest 记录 checkpoint_available=false。下一次续跑前必须检查输出目录、恢复能力和启动脚本，不能将 80 步重启后直接算成 160 步。

08 checkpoint 选择：用代码任务，不用 loss 代替

每个 128 步节点先保存日志与 checkpoint，再依次跑 tokenizer/模型载入检查、固定的函数与多文件仓库任务、重复性检查。所有模型都用同一套系统提示、工具 schema、上下文和生成预算。

评测要冻结模型、提示、工具、任务 hash 与评分器。



图示：按顺序逐关验收；任何一道失败都先修复并重新记录。

指标	为何记录	常见误读
任务通过率	整个任务所需文件/行为都满足的比例	单个隐藏案例通过，不能等于任务完成。
案例通过率	检查每项断言，揭示部分改进与回归	不要只报告更高的案例数而不报任务数。
重复稳定性	每个任务至少多次生成，比较输出与评分一致性	一次随机高分不等于稳定。
验证 loss	检测训练是否可拟合、是否发散	loss 下降不能证明仓库级编码提升。
错误分类	解析失败、工具调用失败、漏文件、测试失败、幻觉回执	分类后调整数据或桥接，不盲目继续训练。

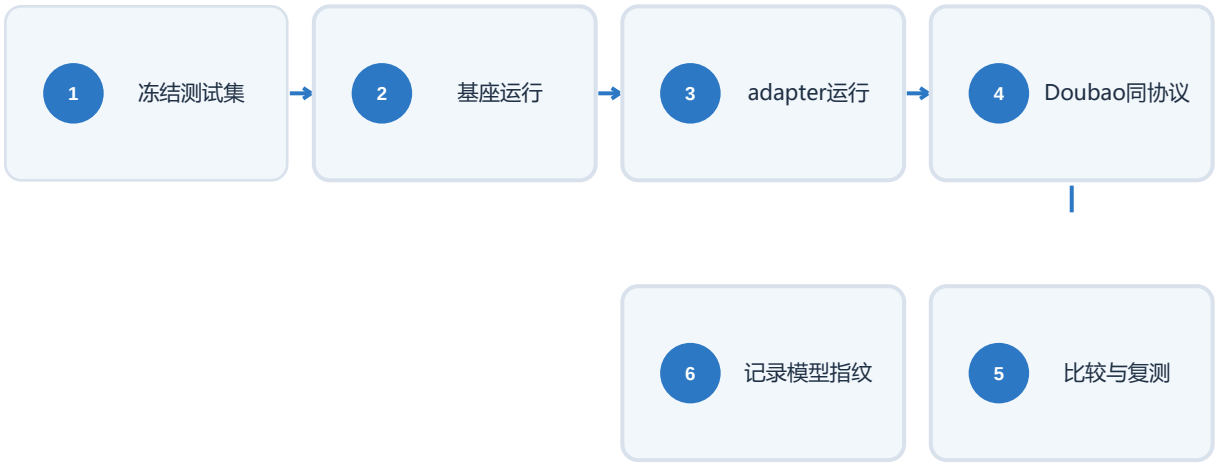
推荐晋级规则
候选 adapter 必须在冻结的独立任务上严格改善基座任务级结果，并在多轮重复中保持；关键任务不允许出现明显回退。若没有胜出，保留原模型并拒绝部署该 adapter。

09 评测闭环：本地基座、adapter 与 Doubao

评测首先回答“微调是否让这台电脑上的基座更好”，再回答“它与 Doubao 相比处于什么位置”。这两种问题不能合成一个指标。Doubao API key 缺失时只报告本地配对结果，不编造外部得分。

比较组	冻结条件	报告
Qwen基座 vs V4 adapter	同任务、同提示、同工具、同输出上限；任务集不进训练	每项任务、隐藏案例、所需文件、稳定性、token/耗时。
V4 adapter vs Doubao	相同工具协议、轮数、token预算、任务集；记录真实返回模型ID	同时报告完整任务率和案例率；计算相对值但不做超样本夸大。
网页实际模型	核对 API `/v1/models`、模型日志、加载权重指纹	确认网页用的是目标 adapter 的合并/转换版本。

每组都存原始 JSON 和汇总表；先写清模型 ID 与 suite SHA。



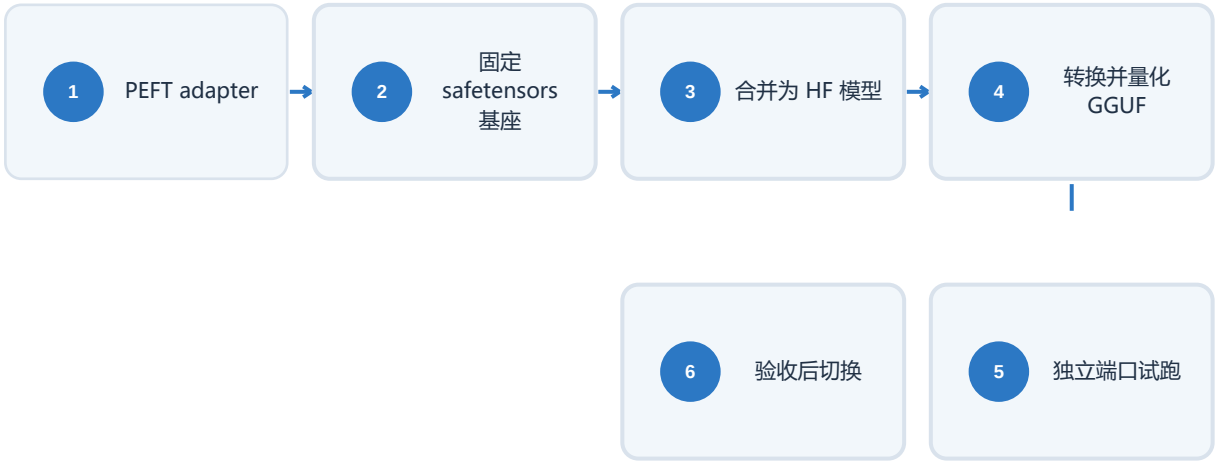
图示：按顺序逐关验收；任何一道失败都先修复并重新记录。

对外能力结论
当前项目没有本次 V4 adapter 的评测分数；没有 Ark 凭证也无法完成同条件 Doubao 对比。不能宣称“达到豆包 2/3”或“代码持平”。目标必须通过真实任务级配对结果验证。

10 adapter 导出与本地 API 切换

训练 adapter 不是 GGUF 成品。安全部署要先合并到与训练完全一致的 Qwen2.5-Coder-7B 基座结构，再转换为 llama.cpp 支持的 GGUF；保留原始基座与现网 GGUF，候选模型使用独立目录和文件名。

转换脚本必须与 Qwen2.5 架构匹配，并记录版本和权重 hash。



图示：按顺序逐关验收；任何一道失败都先修复并重新记录。

COMMAND / CONFIG

```
# ■■■■■■■■■■■■■■■■■■ --help ■■
# 1) ■ PEFT ■ adapter ■■■■■■■■ base■■■■ D ■■■■
# 2) llama.cpp convert_hf_to_gguf.py <merged_hf_dir> --outfile <candidate-f16.gguf>
# 3) llama-quantize <candidate-f16.gguf> <candidate-q4.gguf> Q4_K_M
# 4) ■ 127.0.0.1 ■■■■■■■■■■■■■ /v1/models ■■■■■
```

切换前验收	通过标准
哈希与版本	merged HF/GGUF 均关联训练 run、base revision、adapter hash、转换工具版本。
API冒烟	`GET /v1/models` 显示目标模型；Chat Completions 返回非空、有意义回复。
Agent回归	冻结的小型代码修改套件通过；测试结果由执行器观测，不由模型口述。
网页回归	连续对话、联网搜索、文件生成/上传分别实测；失败有可读状态。
回滚	稳定基座命令和旧模型文件保留；候选未通过时恢复旧 API。

当前网页使用的模型
当前本地网页 API 使用 Qwen2.5-Coder-7B-Instruct Q4 GGUF 基座，没有加载 V4 adapter。完成转换并通过门禁前，不要把候选 adapter 名称写成当前线上模型。

11 网页、搜索和本地 API 的验收

ForgeMind 服务由模型后端、Python API/网页层和浏览器界面组成。当前本机网页端口为 8094，本地推理 API 为 8091。端口只监听回环地址，默认不能从公网访问。

检查	操作	成功证据
模型API	GET http://127.0.0.1:8091/v1/models	返回当前 model id；日志确认加载路径。
网页健康	GET http://127.0.0.1:8094/healthz	返回 status=ok。
基本对话	POST /v1/chat/completions，简单指令	choices[0].message.content 非空。
连续上下文	先给约束，再说“按刚才约束改第二版”	第二轮依赖第一轮内容。
网页搜索	问明确的实时问题；看进度状态、来源卡片、时间戳	等待搜索结束，答案和来源对应，网络故障可见。
文件导出/代码	请求生成 PDF/EPUB/TXT 或小型代码文件	能下载/打开；代码文件落在工作区，默认不自动执行。

COMMAND / CONFIG

```
# ■■■■■■■■■■■■
■■: http://127.0.0.1:8094/
API : http://127.0.0.1:8091/v1
■■: forgemind-qwen25-coder-7b
# ■■■■■■■■■■■■■■■■■■ 0.0.0.0
```

搜索能力的边界
搜索服务会受到网络、地区、公开接口频率和页面可读性的影响；金融行情等问题需要显示查询时间和引用来源。离线或搜索失败时，模型应明确说明，不得拿旧训练知识冒充实时结果。

12 稳定性、安全与常见故障

症状	先检查	处理
CUDA out of memory	是否有本项目 API/推理进程占 GPU；batch/seq 长度；碎片化	等待非本项目任务自然结束；降低 batch/序列或按规划暂停。不要杀未知桌面进程。
loss 突跳或 NaN	数据异常、学习率、精度、梯度裁剪、显存错误	保存错误日志；停止错误 run；从已验证 checkpoint 启动新目录，不覆盖原件。
训练中断无 checkpoint	最近保存步、optimizer state、当前 run 文件	查看 launcher/state/log；无法恢复则从头重新编号，不能将两次不同 run 步数相加。
任务分数上升但真实体验差	评分器漏洞、提示套件过窄、工具回执是假数据	扩展独立仓库任务；检查工具结果是否真实记录；保留真实失败样本。
搜索卡住/答非所问	前端状态、后端 search timeout、查询解析与来源抓取	将搜索状态和生成状态分开；展示阶段、超时与来源；复测指定股票/实时问题。
端口/模型切换异常	端口 PID、模型服务器命令、日志中的模型路径/hash	只关闭确认属于 ForgeMind 的进程；切换失败恢复旧服务。

故障处理要可复现，避免同时改变数据、提示和评分器。



图示：按顺序逐关验收；任何一道失败都先修复并重新记录。

安全原则：API 仅在 localhost；生成代码不自动执行；数据和日志不上传到公共网站；公开源码仓库排除模型权重、训练语料、token/API key、日志中的个人信息、系统快照和临时文件。

13 可复用的 AI 执行清单

以下清单可以直接交给部署 AI 或训练 Agent。AI 应先读取项目 README 与各 manifest，再按阶段操作；每次改动输出证据文件，不允许跳过数据与代码评测门禁。

勾选	必须完成的操作
□	确认工作区、TEMP/TMP、HF cache、训练输出全部在 D 盘；记录 GPU/内存/磁盘快照。
□	核验基座来源与版本、trainer 源码、依赖版本、数据 SHA-256；保存只读 run manifest。
□	运行 exact-tokenizer fit；保留 train/validation/holdout task-group split；执行许可和相似度审核。
□	检查 100 个 verified fixture evidence；不把模型自述或 mock 成功回执当真实测试。
□	达 GPU 门槛后启动单个 512-step pilot；128 步保存/验证；记录断点和 RESTORE 能力。
□	训练后对 base 与 adapter 使用冻结套件配对；任务/案例/稳定性都报告；不按 loss 单独晋级。
□	有 Doubao 凭证时再运行同条件对照；记录真实 model ID、system fingerprint、API 时间与预算。
□	只对胜出的 adapter 执行 merge -> GGUF -> 量化；在独立端口检查 API、网页、代码和搜索。
□	保存失败证据与回滚点；若 adapter 未严格胜出，保留基座并明确拒绝部署候选。

当前交付状态
本 PDF 是完整操作指南和状态快照。V4 训练当前暂停在 80/512，尚无 checkpoint；模型能力、部署切换和 Doubao 对比仍待后续真实验收。

14 参考资料与本机证据

本教程将通用原理、公开上游信息与本机可核验状态分开。以下项目路径保存在 D 盘；如后续数据或脚本更新，应以新的 SHA 和日期更新本手册。

公开上游与技术文档

- MiniMind GitHub 仓库（Apache-2.0）
- MiniMind README：训练流程、模型导出与数据说明
- llama.cpp HTTP Server：本地模型服务与兼容 API

本机证据文件

- eval/forgemind_v4_pilot_launch_20261012.json：计划步数、基座、数据 SHA、训练参数和暂停状态。
- logs/train_forgemind_v4_pilot_20261012_174714.log / .err.log：训练步数和运行错误/警告。
- eval/results/forgemind_v4_training_data_preflight_20261011.json：长度预检与 task-group split。
- eval/results/forgemind_v4_holdout_overlap_audit_20261011.json：冻结 holdout 的文本重叠筛查。
- eval/VERIFIED_AGENT_TOOL_SFT_V4_AUDIT_20261010.md 与 eval/DATASET_V3_V4_RELATION_AUDIT_20261011.md：工具回执验证与数据关系审查。

已证实	仍未证实
MiniMind 上游训练概念与代码入口；V4 数据组成/hash；tokenizer fit；100 个 fixture 测试通过；训练日志记录到 80 步。	本次 V4 训练是否能完成 512 步；adapter 是否提升独立代码任务；是否适合合并量化；是否达到 Doubao 2/3 或代码能力持平。

生成日期：2026-10-12 · 用途：工程复现与本地研发参考 · 外部链接访问日期：2026-10-12